

서울시 상권분석 EDA

한국어 컬럼으로 변환된 데이터를 불러옵니다.

```
In [1]: import pandas as pd
```

한국어 데이터 불러오기

```
In [4]: DATA_DIR = "../data/korean"

DATA_NAMES = [
    "trade_area",
    "stores",
    "sales",
    "floating_population",
    "resident_population",
    "working_population",
    "facilities",
]

datasets = {
    name: pd.read_csv(f"{DATA_DIR}/{name}.csv")
    for name in DATA_NAMES
}

datasets.keys()
```

```
Out[4]: dict_keys(['trade_area', 'stores', 'sales', 'floating_population', 'resident_po
population', 'working_population', 'facilities'])
```

```
In [5]: datasets["trade_area"].head()
```

Out[5]:

	상권_구분_코드	상권_구분_코드명	상권_코드	상권_코드명	X_좌표_EPSG5181	Y_좌표_EPSG5181	자치구_코드	자치구_명	행정동_코드	행정동_명	상권영역_면적제곱미터	원
0	A	골목상권	3110055	황학동버룩시장	201642	452260	11140	중구	11140670	황학동	27575	(
1	A	골목상권	3110008	배화여자대학교(박노수미술관)	197093	453418	11110	종로구	11110515	청운효자동	149264	(
2	A	골목상권	3110009	자하문터널	196991	455057	11110	종로구	11110550	부암동	178306	(
3	A	골목상권	3110010	평창동서측	197064	456643	11110	종로구	11110560	평창동	369415	(
4	A	골목상권	3110017	정독도서관	198581	453781	11110	종로구	11110600	가회동	83855	(

1. 데이터셋 크기 확인

각 데이터의 행 수와 열 수를 확인한다. 행 수가 0이거나 예상한 컬럼 수와 다르면 수집 범위와 저장 과정의 확인이 필요하다. 데이터마다 분석 단위가 다르므로 행 수가 서로 같을 필요는 없다.

```
In [6]: dataset_sizes = pd.DataFrame([
        {"데이터": name, "행 수": df.shape[0], "열 수": df.shape[1]}
        for name, df in datasets.items()
    ])

dataset_sizes
```

```
Out[6]:
```

	데이터	행 수	열 수
0	trade_area	1650	15
1	stores	1604844	18
2	sales	460329	59
3	floating_population	34633	31
4	resident_population	34275	33
5	working_population	34386	30
6	facilities	33138	29

2. 결측값 확인

결측값이 있는 데이터와 컬럼, 개수, 비율을 확인한다. 핵심 키의 결측은 데이터 식별이 불가능하므로 문제로 판단한다. 일반 지표와 관리 컬럼의 결측은 컬럼의 의미와 수집 방식을 확인한 뒤 판단한다.

```
In [7]: missing_list = []

for name, df in datasets.items():
    missing = df.isnull().sum()
    missing = missing[missing > 0]

    for column, count in missing.items():
        missing_rate = count / len(df) * 100
        missing_list.append([name, column, count, missing_rate])

missing_df = pd.DataFrame(
    missing_list,
    columns=["데이터", "컬럼", "결측값 수", "결측률 (%)"],
)

missing_df["결측률 (%)"] = missing_df["결측률 (%)"].round(2)

missing_df
```

```
Out[7]:
```

	데이터	컬럼	결측값 수	결측률 (%)
--	-----	----	-------	---------

3. 중복 행 확인

모든 컬럼 값이 완전히 동일한 행을 확인한다. 중복 행 수가 0이면 정상이다. 0보다 크면 같은 데이터가 반복 저장된 것인지 확인하되, 첫 번째 행은 원본으로 보고 이후 반복

된 행만 중복으로 계산한다.

```
In [8]: duplicate_list = []

for name, df in datasets.items():
    duplicate_count = df.duplicated().sum()
    duplicate_rate = duplicate_count / len(df) * 100

    duplicate_list.append([name, duplicate_count, duplicate_rate])

duplicate_df = pd.DataFrame(
    duplicate_list,
    columns=["데이터", "중복 행 수", "중복률 (%)"],
)

duplicate_df["중복률 (%)"] = duplicate_df["중복률 (%)"].round(2)

duplicate_df
```

Out[8]:

	데이터	중복 행 수	중복률 (%)
0	trade_area	0	0.0
1	stores	0	0.0
2	sales	0	0.0
3	floating_population	0	0.0
4	resident_population	0	0.0
5	working_population	0	0.0
6	facilities	0	0.0

4. 데이터 유효성 탐색

통계적으로 드문 값을 임의로 제거하지 않고, 데이터 구조와 의미가 명확한 최소 조건을 검사한다.

4.1 수치형 기술통계

숫자로 읽힌 코드 컬럼을 제외하고 수치형 지표의 분포를 확인한다. `min` 과 `max` 로 범위를 보고, `mean` 과 50% 의 차이로 치우침을 살펴본다. 이 표만으로 이상값을 확정하지는 않는다.

```
In [9]: for name, df in datasets.items():
    numeric_columns = [
        column
        for column in df.select_dtypes(include="number").columns
        if "코드" not in column
    ]

    print(f"[{name}]")
    display(
        df[numeric_columns]
```

```

        .describe(percentiles=[0.01, 0.25, 0.5, 0.75, 0.99])
        .T
    )

```

[trade_area]

	count	mean	std	min	1%	25%	5
X_좌표 _EPSG5181	1650.0	198981.845455	7280.720618	182509.0	183944.39	192815.25	20009
Y_좌표 _EPSG5181	1650.0	449875.451515	5590.503325	437249.0	439431.66	445178.50	44984
상권_영역_ 면적_제공 미터	1650.0	99927.952121	118818.942812	1854.0	4026.23	35330.00	7192

◀  ▶

[stores]

	count	mean	std	min	1%	25%	50%	75%	99%
유 사 업 종 - 점 포 - 수	1604844.0	6.855240	56.184018	0.0	1.0	1.0	2.0	5.0	
일 반 - 점 포 - 수	1604844.0	6.313860	55.822311	0.0	0.0	1.0	2.0	5.0	
프 랜 차 이 즈 - 점 포 - 수	1604844.0	0.541380	2.402498	0.0	0.0	0.0	0.0	0.0	
개 업 - 점 포 - 수	1604844.0	0.176664	1.182901	0.0	0.0	0.0	0.0	0.0	
개 업 - 율	1604844.0	2.485957	11.169777	0.0	0.0	0.0	0.0	0.0	
폐 업 - 점 포 - 수	1604844.0	0.175380	1.339927	0.0	0.0	0.0	0.0	0.0	
폐 업 - 율	1604844.0	2.376729	11.727200	0.0	0.0	0.0	0.0	0.0	
원 본 - 기	1604844.0	20233.868378	15.086125	20211.0	20211.0	20222.0	20233.0	20244.0	20255.0

	count	mean	std	min	1%	25%	50%	75%	max
준 일 자									

[sales]

	count	mean	std	min	1%	25%	
분기_매출_금액	460329.0	1.024558e+09	9.647683e+09	31.0	1045573.84	45447815.0	170480
분기_매출_건수	460329.0	3.486303e+04	1.626439e+05	1.0	15.00	813.0	4
주중_매출_금액	460329.0	7.733712e+08	6.415428e+09	0.0	499428.04	33560709.0	126988
주말_매출_금액	460329.0	2.511863e+08	3.659304e+09	0.0	0.00	7053635.0	35427
주중_매출_건수	460329.0	2.620528e+04	1.102055e+05	0.0	9.00	617.0	3
주말_매출_건수	460329.0	8.657753e+03	5.860150e+04	0.0	0.00	141.0	
월요일_매출_금액	460329.0	1.480886e+08	1.206649e+09	0.0	0.00	5093198.0	22509
화요일_매출_금액	460329.0	1.521873e+08	1.246270e+09	0.0	0.00	5356720.0	23339
수요일_매출_금액	460329.0	1.502064e+08	1.250183e+09	0.0	0.00	5609362.0	23771
목요일_매출_금액	460329.0	1.522465e+08	1.269047e+09	0.0	0.00	5600942.0	23778
금요일_매출_금액	460329.0	1.706425e+08	1.526784e+09	0.0	0.00	6190997.0	26310
토요일_매출_금액	460329.0	1.561248e+08	2.155053e+09	0.0	0.00	4548524.0	22615
일요일_매출_금액	460329.0	9.506147e+07	1.535615e+09	0.0	0.00	0.0	8247
월요일_매출_건수	460329.0	5.132010e+03	2.107143e+04	0.0	0.00	107.0	
화요일_매출_건수	460329.0	5.130330e+03	2.127435e+04	0.0	0.00	111.0	
수요일_매출_건수	460329.0	5.125053e+03	2.145648e+04	0.0	0.00	115.0	
목요일_매출_건수	460329.0	5.213958e+03	2.205093e+04	0.0	0.00	115.0	

	count	mean	std	min	1%	25%	
금요일_매출_건수	460329.0	5.603926e+03	2.490132e+04	0.0	0.00	127.0	
토요일_매출_건수	460329.0	5.058130e+03	3.342953e+04	0.0	0.00	97.0	
일요일_매출_건수	460329.0	3.599624e+03	2.554624e+04	0.0	0.00	0.0	
시간대_00_06_매출_금액	460329.0	3.153658e+07	8.132248e+08	0.0	0.00	0.0	
시간대_06_11_매출_금액	460329.0	1.169428e+08	1.400551e+09	0.0	0.00	132925.0	5798
시간대_11_14_매출_금액	460329.0	2.663925e+08	2.421831e+09	0.0	0.00	5352700.0	32376
시간대_14_17_매출_금액	460329.0	2.573032e+08	3.019856e+09	0.0	0.00	7429345.0	32877
시간대_17_21_매출_금액	460329.0	2.748548e+08	2.819017e+09	0.0	0.00	11179969.0	46496
시간대_21_24_매출_금액	460329.0	7.752760e+07	4.559324e+08	0.0	0.00	0.0	3037
시간대_00_06_매출_건수	460329.0	1.085952e+03	1.056629e+04	0.0	0.00	0.0	
시간대_06_11_매출_건수	460329.0	5.019544e+03	2.850802e+04	0.0	0.00	6.0	
시간대_11_14_매출_건수	460329.0	9.373658e+03	4.613331e+04	0.0	0.00	105.0	

	count	mean	std	min	1%	25%	
시간대 _14_17_ 매출_건수	460329.0	7.549556e+03	4.581805e+04	0.0	0.00	164.0	
시간대 _17_21_ 매출_건수	460329.0	9.084362e+03	4.375346e+04	0.0	0.00	216.0	1
시간대 _21_24_ 매출_건수	460329.0	2.749960e+03	1.145213e+04	0.0	0.00	0.0	
남성_매 출_금액	460329.0	4.683726e+08	4.697459e+09	0.0	0.00	18436668.0	76340
여성_매 출_금액	460329.0	4.398434e+08	3.649590e+09	0.0	0.00	16721624.0	68630
남성_매 출_건수	460329.0	1.738741e+04	8.140621e+04	0.0	0.00	369.0	2
여성_매 출_건수	460329.0	1.589710e+04	7.718556e+04	0.0	0.00	317.0	1
10대_매 출_금액	460329.0	4.591356e+06	2.723720e+07	0.0	0.00	0.0	125
20대_매 출_금액	460329.0	1.089158e+08	8.211121e+08	0.0	0.00	1114100.0	10498
30대_매 출_금액	460329.0	1.815646e+08	1.729762e+09	0.0	0.00	4401374.0	24061
40대_매 출_금액	460329.0	2.065681e+08	1.893734e+09	0.0	0.00	7045002.0	31853
50대_매 출_금액	460329.0	2.039884e+08	1.925195e+09	0.0	0.00	7829314.0	32871
60대_이 상_매출 _금액	460329.0	2.025891e+08	2.296281e+09	0.0	0.00	4298479.0	21568
10대_매 출_건수	460329.0	4.579792e+02	2.683921e+03	0.0	0.00	0.0	
20대_매 출_건수	460329.0	6.301071e+03	3.021312e+04	0.0	0.00	36.0	
30대_매 출_건수	460329.0	7.850209e+03	3.760474e+04	0.0	0.00	103.0	
40대_매 출_건수	460329.0	6.581631e+03	3.080714e+04	0.0	0.00	154.0	
50대_매 출_건수	460329.0	6.213783e+03	3.015487e+04	0.0	0.00	158.0	

	count	mean	std	min	1%	25%	
60대_이 상_매출 _건수	460329.0	5.879825e+03	4.639807e+04	0.0	0.00	99.0	
원본_기 준_일자	460329.0	2.023363e+04	1.508231e+01	20211.0	20211.00	20222.0	20

[floating_population]

	count	mean	std	min	1%	25%	50%
총_유동 인구_수	34633.0	822067.853030	885236.305624	4.0	14225.40	221737.0	558510.0
남성_유 동인구_수	34633.0	391185.471602	428725.985058	0.0	6941.64	106458.0	264936.0
여성_유 동인구_수	34633.0	430882.398522	459895.693354	0.0	7186.56	115387.0	292905.0
10대_유 동인구_수	34633.0	104662.057691	112368.782430	0.0	1275.64	25409.0	69809.0
20대_유 동인구_수	34633.0	145511.864465	207658.729747	0.0	1573.64	31612.0	81688.0
30대_유 동인구_수	34633.0	145451.199521	179246.634177	0.0	2082.64	36018.0	92440.0
40대_유 동인구_수	34633.0	133524.096988	151133.583987	0.0	2342.00	36477.0	89686.0
50대_유 동인구_수	34633.0	120417.955534	127574.840872	0.0	2231.92	33332.0	82774.0
60대_이 상_유동 인구_수	34633.0	172500.763232	180121.425230	0.0	3175.56	46285.0	118721.0
시간대 -00_06_ 유동인 구_수	34633.0	196763.412295	209497.099292	0.0	2558.64	48266.0	129826.0
시간대 -06_11_ 유동인 구_수	34633.0	167591.084688	177438.910960	0.0	2950.32	45802.0	115447.0
시간대 -11_14_ 유동인 구_수	34633.0	106346.246268	131486.899588	0.0	1841.00	28309.0	71102.0
시간대 -14_17_ 유동인 구_수	34633.0	107430.225710	134519.139569	0.0	1909.96	28626.0	71155.0
시간대 -17_21_ 유동인 구_수	34633.0	142548.825138	164271.094150	0.0	2501.28	38525.0	94796.0

	count	mean	std	min	1%	25%	50%
시간대 _21_24_ 유동인 구_수	34633.0	101388.121907	107469.275595	0.0	1548.92	26063.0	68364.0
월요일_ 유동인 구_수	34633.0	117802.131118	127743.305923	0.0	2004.28	31640.0	80212.0
화요일_ 유동인 구_수	34633.0	118446.025554	129607.669704	0.0	2001.32	31738.0	80347.0
수요일_ 유동인 구_수	34633.0	118778.951982	130218.990875	0.0	2034.96	31861.0	80513.0
목요일_ 유동인 구_수	34633.0	118808.489995	130508.422691	0.0	2019.32	31933.0	80450.0
금요일_ 유동인 구_수	34633.0	118680.683568	130765.358756	0.0	2011.64	31912.0	80392.0
토요일_ 유동인 구_수	34633.0	115652.714810	123588.538311	0.0	1964.00	30944.0	78673.0
일요일_ 유동인 구_수	34633.0	113898.946496	119024.373655	0.0	1860.12	30275.0	77711.0
원본_기 준_일자	34633.0	20233.852742	15.117289	20211.0	20211.00	20222.0	20233.0

[resident_population]

	count	mean	std	min	1%	25%	50%	75%	
총_상주인구_수	34275.0	2322.584041	2280.774480	1.0	7.0	640.0	1617.0	3271.0	9
남성_상주인구_수	34275.0	1138.400963	1118.233946	0.0	4.0	319.0	800.0	1607.0	4
여성_상주인구_수	34275.0	1184.183078	1170.422729	0.0	2.0	322.0	822.0	1685.0	5
10대_상주인구_수	34275.0	224.611466	254.320815	0.0	0.0	51.0	144.0	312.0	1
20대_상주인구_수	34275.0	388.425791	451.338135	0.0	0.0	89.0	251.0	529.0	2
30대_상주인구_수	34275.0	400.805748	442.821182	0.0	0.0	97.0	265.0	557.0	2
40대_상주인구_수	34275.0	335.852691	349.687835	0.0	1.0	86.0	226.0	468.0	1
50대_상주	34275.0	360.389292	360.825104	0.0	1.0	95.0	249.0	516.0	1

	count	mean	std	min	1%	25%	50%	75%	
인구_수									
60대_이상_상주인구_수	34275.0	612.499052	610.413556	0.0	2.0	165.0	427.0	862.0	2
남성_10대_상주인구_수	34275.0	115.025996	130.666794	0.0	0.0	26.0	74.0	160.0	
남성_20대_상주인구_수	34275.0	182.515186	208.128235	0.0	0.0	43.0	119.0	251.0	
남성_30대_상주인구_수	34275.0	206.491204	227.982938	0.0	0.0	50.0	138.0	286.0	1
남성_40대_상주인구_수	34275.0	172.769365	179.056933	0.0	0.0	46.0	118.0	238.0	
남성_50대_상주	34275.0	181.064683	179.023429	0.0	1.0	49.0	126.0	258.0	

	count	mean	std	min	1%	25%	50%	75%	
인구_수									
남성_60대_이상_상주인구_수	34275.0	280.534530	278.524602	0.0	1.0	78.0	195.0	392.0	1
여성_10대_상주인구_수	34275.0	109.585470	124.333451	0.0	0.0	25.0	70.0	152.0	
여성_20대_상주인구_수	34275.0	205.910605	251.914340	0.0	0.0	44.0	128.0	273.0	1
여성_30대_상주인구_수	34275.0	194.314544	219.387058	0.0	0.0	46.0	126.0	265.0	1
여성_40대_상주인구_수	34275.0	163.083326	172.944869	0.0	0.0	40.0	108.0	230.0	
여성_50대_상주인구_수	34275.0	179.324610	183.977306	0.0	0.0	45.0	121.0	256.0	

	count	mean	std	min	1%	25%	50%	75%	
상주인구수									
여성_60대 이상_상주인구수	34275.0	331.964522	333.850011	0.0	1.0	87.0	230.0	469.0	1
총가구수	34275.0	1284.087819	1265.808079	1.0	5.0	365.0	912.0	1821.0	5
아파트가구수	34275.0	0.000000	0.000000	0.0	0.0	0.0	0.0	0.0	
비아파트가구수	34275.0	1284.087819	1265.808079	1.0	5.0	365.0	912.0	1821.0	5
원본기준일자	34275.0	20233.857389	15.121969	20211.0	20211.0	20222.0	20233.0	20244.0	20

[working_population]

	count	mean	std	min	1%	25%	50%	75%	
총_직장인_구_수	34386.0	2719.904961	10431.143442	1.0	11.0	188.0	461.0	1261.0	4
남성_직장인_구_수	34386.0	1662.289798	6491.023931	0.0	6.0	107.0	269.0	739.0	2
여성_직장인_구_수	34386.0	1057.615163	4016.414319	0.0	3.0	76.0	185.0	503.0	1
10대_직장인_구_수	34386.0	6.330512	38.557341	0.0	0.0	0.0	0.0	0.0	
20대_직장인_구_수	34386.0	492.168412	2024.591571	0.0	0.0	19.0	60.0	193.0	
30대_직장인_구_수	34386.0	781.080352	3305.607712	0.0	1.0	38.0	105.0	314.0	1
40대_직장인_구_수	34386.0	694.679114	2706.820061	0.0	3.0	46.0	115.0	314.0	1
50대_직장	34386.0	513.066859	1810.692292	0.0	3.0	43.0	109.0	278.0	

	count	mean	std	min	1%	25%	50%	75%
인구_수								
60대_이상_직장인_구_수	34386.0	232.579713	684.375201	0.0	1.0	25.0	62.0	160.0
남성_10대_직장인_구_수	34386.0	2.536992	16.206749	0.0	0.0	0.0	0.0	0.0
남성_20대_직장인_구_수	34386.0	225.880678	952.590171	0.0	0.0	7.0	27.0	88.0
남성_30대_직장인_구_수	34386.0	473.369424	2048.881625	0.0	0.0	20.0	59.0	182.0
남성_40대_직장인_구_수	34386.0	460.034374	1867.299378	0.0	1.0	26.0	67.0	191.0
남성_50대_직장	34386.0	341.364509	1247.191436	0.0	1.0	25.0	64.0	168.0

	count	mean	std	min	1%	25%	50%	75%
인구_수								
남성_60대_이상_직장인_구_수	34386.0	159.103821	453.184229	0.0	1.0	18.0	45.0	113.0
여성_10대_직장인_구_수	34386.0	3.793521	23.246386	0.0	0.0	0.0	0.0	0.0
여성_20대_직장인_구_수	34386.0	266.287733	1092.281031	0.0	0.0	11.0	32.0	105.0
여성_30대_직장인_구_수	34386.0	307.710929	1296.118946	0.0	0.0	16.0	43.0	127.0
여성_40대_직장인_구_수	34386.0	234.644739	862.322483	0.0	1.0	19.0	47.0	118.0
여성_50대_	34386.0	171.702350	619.876397	0.0	1.0	16.0	40.0	101.0

	count	mean	std	min	1%	25%	50%	75%
직장인 구_수								
여성_60 대_이 상_직 장인 구_수	34386.0	73.475891	239.282345	0.0	0.0	5.0	16.0	48.0
원 본_기 준_일 자	34386.0	20233.874571	15.120011	20211.0	20211.0	20222.0	20233.0	20244.0

[facilities]

	count	mean	std	min	1%	25%	50%	75%	99
총 - 집객시설 - 수	33138.0	20.871356	32.260254	1.0	1.0	5.0	12.0	23.0	158
관 공 서 - 수	33138.0	0.695184	1.171712	0.0	0.0	0.0	0.0	1.0	5
은 행 - 수	33138.0	1.014575	3.009396	0.0	0.0	0.0	0.0	1.0	13
중 합 병 원 - 수	33138.0	0.015209	0.127459	0.0	0.0	0.0	0.0	0.0	1
일 반 병 원 - 수	33138.0	0.107098	0.395562	0.0	0.0	0.0	0.0	0.0	2
약 국 - 수	33138.0	2.359316	4.033607	0.0	0.0	0.0	1.0	3.0	20
유 치 원 - 수	33138.0	0.111534	0.385393	0.0	0.0	0.0	0.0	0.0	2
초 등 학 교 - 수	33138.0	0.008238	0.090392	0.0	0.0	0.0	0.0	0.0	0
중 학 교 - 수	33138.0	0.002535	0.050284	0.0	0.0	0.0	0.0	0.0	0
고 등	33138.0	0.008238	0.109421	0.0	0.0	0.0	0.0	0.0	0

	count	mean	std	min	1%	25%	50%	75%	99
학교 수									
대학교 수	33138.0	0.087452	0.465503	0.0	0.0	0.0	0.0	0.0	2
백화점 수	33138.0	0.007605	0.093885	0.0	0.0	0.0	0.0	0.0	0
슈퍼마켓 수	33138.0	0.102028	0.494959	0.0	0.0	0.0	0.0	0.0	2
극장 수	33138.0	0.072243	0.352225	0.0	0.0	0.0	0.0	0.0	2
숙박시설 수	33138.0	0.212928	1.027044	0.0	0.0	0.0	0.0	0.0	5
공항 수	33138.0	0.002535	0.100664	0.0	0.0	0.0	0.0	0.0	0
철도역 수	33138.0	0.000000	0.000000	0.0	0.0	0.0	0.0	0.0	0
버스터미널 수	33138.0	0.001267	0.035579	0.0	0.0	0.0	0.0	0.0	0
지하철역	33138.0	0.175539	0.535430	0.0	0.0	0.0	0.0	0.0	3

	count	mean	std	min	1%	25%	50%	75%	99
수									
버 스 정 류 장	33138.0	3.896071	4.958773	0.0	0.0	1.0	3.0	5.0	21
수									
원 본									
기 준	33138.0	20233.857143	15.116557	20211.0	20211.0	20222.0	20233.0	20244.0	20261
일 자									

4.2 핵심 키 고유성

각 데이터의 분석 단위를 나타내는 핵심 키 조합이 한 행씩만 존재하는지 확인한다. 전체 행 수와 고유 키 수가 같고 중복 키 수가 0이면 정상이다.

```
In [10]: KEY_COLUMNS = {
    "trade_area": ["상권_코드"],
    "stores": ["기준_년분기_코드", "상권_코드", "서비스_업종_코드"],
    "sales": ["기준_년분기_코드", "상권_코드", "서비스_업종_코드"],
    "floating_population": ["기준_년분기_코드", "상권_코드"],
    "resident_population": ["기준_년분기_코드", "상권_코드"],
    "working_population": ["기준_년분기_코드", "상권_코드"],
    "facilities": ["기준_년분기_코드", "상권_코드"],
}

key_check_list = []

for name, key_columns in KEY_COLUMNS.items():
    df = datasets[name]
    unique_key_count = df[key_columns].drop_duplicates().shape[0]
    duplicate_key_count = df.duplicated(subset=key_columns).sum()

    key_check_list.append([
        name,
        " + ".join(key_columns),
        len(df),
        unique_key_count,
        duplicate_key_count,
    ])

key_check_df = pd.DataFrame(
    key_check_list,
    columns=["데이터", "핵심 키", "전체 행 수", "고유 키 수", "중복 키 수"],
)
```


key_check_df

Out[10]:

	데이터	핵심 키	전체 행 수	고유 키 수	중복 키 수
0	trade_area	상권_코드	1650	1650	0
1	stores	기준_년분기_코드 + 상권_코드 + 서비스_업종_코드	1604844	1604844	0
2	sales	기준_년분기_코드 + 상권_코드 + 서비스_업종_코드	460329	460329	0
3	floating_population	기준_년분기_코드 + 상권_코드	34633	34633	0
4	resident_population	기준_년분기_코드 + 상권_코드	34275	34275	0
5	working_population	기준_년분기_코드 + 상권_코드	34386	34386	0
6	facilities	기준_년분기_코드 + 상권_코드	33138	33138	0

4.3 상권 코드 참조 확인

점포·매출·인구·시설 데이터의 상권 코드가 상권 마스터인 `trade_area`에 존재하는지 확인한다. `미등록 상권 코드 수`와 `미등록 행 수`가 모두 0이면 정상이다. 데이터별 상권 코드 수 자체는 수집 기간과 제공 범위에 따라 다를 수 있다.

```
In [11]: trade_area_codes = set(datasets["trade_area"]["상권_코드"])
reference_list = []

for name, df in datasets.items():
    if name == "trade_area":
        continue

    not_in_master = ~df["상권_코드"].isin(trade_area_codes)

    reference_list.append([
        name,
        df["상권_코드"].nunique(),
        df.loc[not_in_master, "상권_코드"].nunique(),
        not_in_master.sum(),
    ])

reference_df = pd.DataFrame(
    reference_list,
    columns=["데이터", "상권 코드 수", "미등록 상권 코드 수", "미등록 행 수"],
)

reference_df
```

Out[11]:

	데이터	상권 코드 수	미등록 상권 코드 수	미등록 행 수
0	stores	1650	0	0
1	sales	1596	0	0
2	floating_population	1650	0	0
3	resident_population	1637	0	0
4	working_population	1643	0	0
5	facilities	1578	0	0

4.4 코드와 명칭의 일관성

하나의 코드에 서로 다른 명칭이 연결되어 있는지 확인한다. 여러 명칭이 연결된 코드 수 가 0이면 정상이다. 0보다 크면 명칭 변경, 오탈자 또는 코드 매핑 문제인지 확인한다.

In [12]:

```
CODE_NAME_PAIRS = [
    ("상권_코드", "상권_코드명"),
    ("상권_구분_코드", "상권_구분_코드명"),
    ("서비스_업종_코드", "서비스_업종_코드명"),
    ("자치구_코드", "자치구_명"),
    ("행정동_코드", "행정동_명"),
]

code_name_list = []

for name, df in datasets.items():
    for code_column, name_column in CODE_NAME_PAIRS:
        if code_column in df.columns and name_column in df.columns:
            name_count = df.groupby(code_column)[name_column].nunique()
            inconsistent_count = (name_count > 1).sum()

            code_name_list.append([
                name,
                code_column,
                name_column,
                inconsistent_count,
            ])

code_name_df = pd.DataFrame(
    code_name_list,
    columns=["데이터", "코드 컬럼", "명칭 컬럼", "여러 명칭이 연결된 코드 수"],
)

code_name_df
```

Out[12]:

	데이터	코드 컬럼	명칭 컬럼	여러 명칭이 연결된 코드 수
0	trade_area	상권_코드	상권_코드명	0
1	trade_area	상권_구분_코드	상권_구분_코드명	0
2	trade_area	자치구_코드	자치구_명	0
3	trade_area	행정동_코드	행정동_명	0
4	stores	상권_코드	상권_코드명	2
5	stores	상권_구분_코드	상권_구분_코드명	0
6	stores	서비스_업종_코드	서비스_업종_코드명	0
7	sales	상권_코드	상권_코드명	2
8	sales	상권_구분_코드	상권_구분_코드명	0
9	sales	서비스_업종_코드	서비스_업종_코드명	0
10	floating_population	상권_코드	상권_코드명	2
11	floating_population	상권_구분_코드	상권_구분_코드명	0
12	resident_population	상권_코드	상권_코드명	2
13	resident_population	상권_구분_코드	상권_구분_코드명	0
14	working_population	상권_코드	상권_코드명	2
15	working_population	상권_구분_코드	상권_구분_코드명	0
16	facilities	상권_코드	상권_코드명	2
17	facilities	상권_구분_코드	상권_구분_코드명	0

4.5 수치형 값의 최소 조건

금액·인구·점포·시설 수는 음수 개수와 무한대 개수가 0이어야 한다. 건수형 컬럼은 소수 개수도 0이어야 한다. 비율은 0~100, 면적은 0 초과를 정상 범위로 본다. 0 개수는 참고값이며 매출·점포·시설에서 0은 정상일 수 있으므로 오류로 판단하지 않는다.

In [13]:

```
numeric_check_list = []

for name, df in datasets.items():
    numeric_columns = [
        column
        for column in df.select_dtypes(include="number").columns
        if "코드" not in column
    ]

    for column in numeric_columns:
        values = df[column]
        negative_count = (values < 0).sum()
        zero_count = (values == 0).sum()
        infinity_count = values.isin([float("inf"), float("-inf")]).sum()
```

```

decimal_count = 0
if column.endswith("_수") or column.endswith("_건수"):
    decimal_count = ((values.dropna() % 1) != 0).sum()

range_error_count = 0
if column.endswith("_율"):
    range_error_count = ((values < 0) | (values > 100)).sum()
elif "면적" in column:
    range_error_count = (values <= 0).sum()

numeric_check_list.append([
    name, column, values.min(), values.max(),
    negative_count, zero_count, decimal_count,
    infinity_count, range_error_count,
])

numeric_check_df = pd.DataFrame(
    numeric_check_list,
    columns=[
        "데이터", "컬럼", "최솟값", "최댓값", "음수 개수",
        "0 개수", "소수 개수", "무한대 개수", "범위 오류 개수",
    ],
)

numeric_check_df

```

Out[13]:

	데이터	컬럼	최솟값	최댓값	음수 개수	0 개수	소수 개수	무한대 개수	범위 오류 개수
0	trade_area	X_좌표_EPSG5181	182509.0	215352.0	0	0	0	0	0
1	trade_area	Y_좌표_EPSG5181	437249.0	465573.0	0	0	0	0	0
2	trade_area	상권_영역_면적_제곱미터	1854.0	2462734.0	0	0	0	0	0
3	stores	유사업종_점포_수	0.0	12934.0	0	11095	0	0	0
4	stores	일반_점포_수	0.0	12925.0	0	56092	0	0	0
...	...	...	...	...	...	...	...	...	...
146	facilities	철도역_수	0.0	0.0	0	33138	0	0	0
147	facilities	버스터미널_수	0.0	1.0	0	33096	0	0	0
148	facilities	지하철역_수	0.0	5.0	0	29043	0	0	0
149	facilities	버스정류장_수	0.0	85.0	0	6468	0	0	0
150	facilities	원본_기준_일자	20211.0	20261.0	0	0	0	0	0

151 rows × 9 columns

4.6 분기 코드 형식

분기 코드가 연도 4자리와 분기 1자리로 구성됐는지 확인한다. 예를 들어 20241 은 2024년 1분기를 의미한다. 마지막 자리는 1~4만 허용하며 형식 오류 수 가 0이면 정상이다.

```
In [14]: quarter_list = []

for name, df in datasets.items():
    if "기준_년분기_코드" not in df.columns:
        continue

    quarter = df["기준_년분기_코드"].astype("string")
    invalid_count = (~quarter.str.fullmatch(r"\d{4}[1-4]", na=False)).sum()

    quarter_list.append([
        name,
        quarter.nunique(),
        quarter.min(),
        quarter.max(),
        invalid_count,
    ])

quarter_df = pd.DataFrame(
    quarter_list,
    columns=["데이터", "분기 수", "최초 분기", "최근 분기", "형식 오류 수"],
)

quarter_df
```

```
Out[14]:
```

	데이터	분기 수	최초 분기	최근 분기	형식 오류 수
0	stores	21	20211	20261	0
1	sales	21	20211	20261	0
2	floating_population	21	20211	20261	0
3	resident_population	21	20211	20261	0
4	working_population	21	20211	20261	0
5	facilities	21	20211	20261	0

4.7 주요 총계와 구성값의 일치

총계가 주요 구성값의 합과 일치하는지 확인한다. 원천 데이터의 반올림을 고려해 절대 차이가 1 이하이면 일치로 판단한다. 불일치 행 수 가 0이면 정상이다. 세부 항목이 전체 구성을 완전히 포함한다고 확신할 수 없는 시설 데이터는 이 검사에서 제외한다.

```
In [15]: SUM_RULES = {
    "stores": [
        ("유사업종 점포 수", "유사업종_점포_수", ["일반_점포_수", "프랜차이즈_점포_수"],
    ],
    "sales": [
        ("분기 매출 금액", "분기_매출_금액", ["주중_매출_금액", "주말_매출_금액"])
```

```

        ("분기 매출 건수", "분기_매출_건수", ["주중_매출_건수", "주말_매출_건수"]),
    ],
    "floating_population": [
        ("총 유동인구 수", "총_유동인구_수", ["남성_유동인구_수", "여성_유동인구_수"]),
    ],
    "resident_population": [
        ("총 상주인구 수", "총_상주인구_수", ["남성_상주인구_수", "여성_상주인구_수"]),
        ("총 가구 수", "총_가구_수", ["아파트_가구_수", "비아파트_가구_수"]),
    ],
    "working_population": [
        ("총 직장인구 수", "총_직장인구_수", ["남성_직장인구_수", "여성_직장인구_수"]),
    ],
}

sum_check_list = []

for name, rules in SUM_RULES.items():
    df = datasets[name]

    for check_name, total_column, part_columns in rules:
        part_sum = df[part_columns].sum(axis=1, min_count=len(part_columns))
        difference = (df[total_column] - part_sum).abs()
        mismatch_count = (difference > 1).sum()

        sum_check_list.append([
            name, check_name, mismatch_count, difference.max(),
        ])

sum_check_df = pd.DataFrame(
    sum_check_list,
    columns=["데이터", "검사 항목", "불일치 행 수", "최대 차이"],
)

sum_check_df

```

Out[15]:

	데이터	검사 항목	불일치 행 수	최대 차이
0	stores	유사업종 점포 수	0	0.0
1	sales	분기 매출 금액	0	0.0
2	sales	분기 매출 건수	0	0.0
3	floating_population	총 유동인구 수	2610	3.0
4	resident_population	총 상주인구 수	0	0.0
5	resident_population	총 가구 수	0	0.0
6	working_population	총 직장인구 수	0	0.0

5. 데이터 유효성 검사 결과 해석

항목	판단	분석 결과
4.1 수 치형 기 술통계	참고	수치형 지표에서 음수·무한대·소수형 건수는 발견되지 않았다. 매출·인구·시설 데이터에는 0이 다수 존재하지만, 영업이나 시설이 없는 경우를 나타낼

항목	판단	분석 결과
		수 있으므로 0 자체를 오류로 판단하지 않는다. 기술통계의 큰 최댓값은 실제 대형 상권일 수 있어 별도 아웃라이어로 제거하지 않는다.
4.2 핵심 키 고유성	정상	7개 데이터 모두 전체 행 수와 고유 핵심 키 조합 수가 같고 중복 키 수가 0이다. 따라서 현재 정의한 분석 단위에서 중복 레코드는 없다.
4.3 상권 코드 참조	정상	모든 데이터의 상권 코드가 <code>trade_area</code> 에 등록되어 있으며 미등록 상권 코드와 미등록 행은 0건이다. 데이터별 상권 수 차이는 제공 범위 차이로 볼 수 있다.
4.4 코드와 명칭의 일관성	검토 필요	시계열 데이터에서 상권 코드 2개가 서로 다른 명칭을 사용한다. 3110024는 혜화동주민센터 와 혜화동주민센터 , 3110379는 KT&G 북부지사와 KTNG 북부지사가 함께 존재한다. 시기별 명칭 변경 또는 표기 차이로 보이며, 분석용 명칭은 <code>trade_area</code> 기준으로 통일할지 결정할 필요가 있다.
4.5 수치형 최소 조건	대체로 정상	모든 데이터에서 음수·무한대·계수형 소수값은 0건이다. 다만 <code>stores</code> 에서 개업률 100 초과가 14건(최대 200), 폐업률 100 초과가 767건(최대 500) 확인됐다. 공식 데이터 설명은 두 컬럼을 개업률·폐업률 수치로 제공하지만 상한을 명시하지 않으므로, 현재의 0~100 기준은 확정 오류가 아니라 검토 기준으로 해석한다.
4.6 분기 코드 형식	정상	분기형 데이터 6종 모두 2021년 1분기(20211)부터 2026년 1분기(20261)까지 21개 분기를 포함하며 형식 오류는 0건이다.
4.7 총계와 구성값 일치	대체로 정상	점포, 매출, 상주인구, 가구, 직장인구는 모두 허용 오차 안에서 일치한다. 유동인구는 2,610행이 현재 허용 오차 1을 넘지만 최대 차이가 3명에 불과하므로 집계·반올림 차이로 해석할 수 있다. 유동인구에 한해 허용 오차를 3으로 조정하는 것이 적절하다.

종합 판단

핵심 키, 상권 코드 참조, 분기 형식과 주요 합계 관계는 전반적으로 정상이다. 현재 즉시 제거해야 할 명확한 오류값은 발견되지 않았다. 후속 작업에서는 상권명 2개 코드의 표기 통일 여부를 정하고, 개·폐업률 100 초과 값을 원천 산식에 따라 해석하며, 유동인구 합계 검사 허용 오차를 3으로 조정하는 것이 좋다.

참고: [서울시 상권분석서비스 점포-상권 데이터 설명](#)

6. 검토 항목 추가 탐색

6.1 개업률·폐업률 100% 초과

100을 초과한 비율의 건수와 최댓값을 확인하고, 해당 행의 전체 점포 수와 개·폐업 점포 수를 함께 살펴본다. 전체 점포 수보다 한 분기 동안 개업하거나 폐업한 점포 수가 많다면 비율은 100을 초과할 수 있다.

```
In [16]: stores = datasets["stores"]
```

```

rate_summary = pd.DataFrame({
    "항목": ["개업률", "폐업률"],
    "100 초과 행 수": [
        (stores["개업_율"] > 100).sum(),
        (stores["폐업_율"] > 100).sum(),
    ],
    "최댓값": [stores["개업_율"].max(), stores["폐업_율"].max()],
})

display(rate_summary)

rate_review = stores.loc[
    (stores["개업_율"] > 100) | (stores["폐업_율"] > 100),
    [
        "기준_년분기_코드", "상권_코드명", "서비스_업종_코드명",
        "유사업종_점포_수", "개업_점포_수", "개업_율",
        "폐업_점포_수", "폐업_율",
    ],
]

rate_review.sort_values(
    ["폐업_율", "개업_율"],
    ascending=False,
).head(30)

```

	항목	100 초과 행 수	최댓값
0	개업률	14	200.0
1	폐업률	767	500.0

Out[16]:

	기준_년분 기_코드	상권_코드명	서비스_ 업종_코 드명	유사업 종_점포 _수	개업_ 점포_ 수	개업_ 율	폐업_ 점포_ 수	폐업_ 율
1111218	20223	이수역 10번	자동차수리	1.0	0.0	0.0	5.0	500.0
350826	20251	염창무학아파트	전자상거래업	2.0	0.0	0.0	9.0	450.0
255567	20252	종림동	스포츠강습	1.0	0.0	0.0	4.0	400.0
308066	20251	송화벽화시장(송화골목시장)	전자상거래업	1.0	0.0	0.0	4.0	400.0
889407	20232	까치산역 3번	PC방	1.0	0.0	0.0	4.0	400.0
991203	20231	한강진역 3번	예술학원	1.0	0.0	0.0	4.0	400.0
6927	20261	장위전통시장	미곡판매	1.0	1.0	100.0	3.0	300.0
117460	20254	대림1동주민센터	치킨전문점	1.0	1.0	100.0	3.0	300.0
129390	20254	경의중앙 신촌역	편의점	1.0	1.0	100.0	3.0	300.0
401699	20244	등촌역	가전제품수리	1.0	1.0	100.0	3.0	300.0
922926	20231	신월3동 골목시장	한식음식점	1.0	1.0	100.0	3.0	300.0
974476	20231	응암동우체국	치킨전문점	1.0	1.0	100.0	3.0	300.0
1520422	20212	홍릉시장	중식음식점	1.0	1.0	100.0	3.0	300.0
3833	20261	목2동시장	청과상	1.0	0.0	0.0	3.0	300.0
58761	20261	도봉구민회관	스포츠클럽	1.0	0.0	0.0	3.0	300.0
76215	20254	장신구 특화거리 상점가	전자상거래업	1.0	0.0	0.0	3.0	300.0
81211	20254	모래내시장(서중시장)	호프-간이주점	1.0	0.0	0.0	3.0	300.0
115978	20254	노량진역 6번	양식음식점	2.0	0.0	0.0	6.0	300.0
223705	20253	신금호역 4번	커피-음료	1.0	0.0	0.0	3.0	300.0
265167	20252	서울대입구역 8번	일식음식점	1.0	0.0	0.0	3.0	300.0

	기준_년분 기_코드	상권_코드명	서비스_업종_코 드명	유사업 종_점포 _수	개업_점포_수	개업_율	폐업_점포_수	폐업_율
331567	20251	북창동(시청 역_6번)	전자상거 래업	1.0	0.0	0.0	3.0	300.0
342915	20251	난우초등학 교	편의점	1.0	0.0	0.0	3.0	300.0
400851	20244	개봉동 현대 아파트	편의점	1.0	0.0	0.0	3.0	300.0
448735	20244	고려대역 6 번	전자상거 래업	1.0	0.0	0.0	3.0	300.0
466339	20243	무학봉상점 가	패스트푸 드점	1.0	0.0	0.0	3.0	300.0
466414	20243	신금호역 골 목형상점가	양식음식 점	1.0	0.0	0.0	3.0	300.0
469107	20243	가락시장역	기타오락 장	1.0	0.0	0.0	3.0	300.0
480796	20243	월곡역	수산물판 매	1.0	0.0	0.0	3.0	300.0
490317	20243	삼전역 4번	여행사	1.0	0.0	0.0	3.0	300.0
513033	20243	응암동우체 국	패스트푸 드점	1.0	0.0	0.0	3.0	300.0

6.2 유동인구 성별 합계 차이

총 유동인구 - 남성 유동인구 - 여성 유동인구 를 계산해 차이의 전체 분포를 확인한다. 차이가 작은 정수 범위에만 집중되어 있으면 개별 성별 값의 반올림 과정에서 발생한 차이로 볼 수 있다.

```
In [17]: floating = datasets["floating_population"]

floating_difference = (
    floating["총_유동인구_수"]
    - floating["남성_유동인구_수"]
    - floating["여성_유동인구_수"]
)

floating_difference_df = (
    floating_difference.value_counts()
    .sort_index()
    .rename_axis("합 계 차 이")
    .reset_index(name="행 수")
)

floating_difference_df
```

Out[17]:

	합계 차이	행 수
0	-3.0	59
1	-2.0	1304
2	-1.0	7610
3	0.0	17167
4	1.0	7246
5	2.0	1184
6	3.0	63

6.3 상권명 변경 이력

여러 명칭이 연결된 상권 코드 2개의 분기별 명칭을 확인한다. 특정 분기를 기준으로 모든 데이터에서 동일하게 명칭이 바뀌었다면 무작위 오류보다는 원천의 명칭 정비 또는 변경으로 해석할 수 있다.

```
In [18]: review_codes = [3110024, 3110379]
name_history_list = []

for name, df in datasets.items():
    if "기준_년분기_코드" not in df.columns:
        continue

    history = df.loc[
        df["상권_코드"].isin(review_codes),
        ["기준_년분기_코드", "상권_코드", "상권_코드명"],
    ].drop_duplicates()

    history.insert(0, "데이터", name)
    name_history_list.append(history)

name_history_df = pd.concat(name_history_list, ignore_index=True)

name_history_df.sort_values(
    ["상권_코드", "기준_년분기_코드", "데이터"]
)
```

Out[18]:

	데이터	기준_년분기_코드	상권_코드	상권_코드명
212	facilities	20211	3110024	혜회동주민센터
98	floating_population	20211	3110024	혜회동주민센터
141	resident_population	20211	3110024	혜회동주민센터
71	sales	20211	3110024	혜회동주민센터
41	stores	20211	3110024	혜회동주민센터
...	...	...	...	...
248	facilities	20261	3110379	KTNG 북부지사
122	floating_population	20261	3110379	KTNG 북부지사
161	resident_population	20261	3110379	KTNG 북부지사
0	stores	20261	3110379	KTNG 북부지사
201	working_population	20261	3110379	KTNG 북부지사

249 rows × 4 columns

추가 탐색 결과

- 개·폐업률:** 개업률 100 초과는 14행, 폐업률 100 초과는 767행이다. 제공 기관에서 실제 산식을 제공하고 있지 않아서 정확한 판단을 할 수 없지만, 기준 분기의 점포 수를 분모로 계산하는 것으로 추정된다. 또한 실제 연구자료나 언론보도에서 폐업률을 100% 초과한 수치를 언급하는 것으로 보아 우선 개업률과 폐업률을 이상치로 언급만 하고 우리 분석에서는 그대로 사용하기로 한다.
- 유동인구 합계:** 총계와 세부 합계 사이에 작은 차이가 확인되지만, 공식 문서에는 반올림 방식이나 합계 일치 조건이 명시되어 있지 않다. 그러므로 이를 단순 반올림으로 단정하지 않고 원천 추정·공간배분·집계 과정에서 발생한 미세한 집계 잔차로 간주하는 것이 적절하며 오차율이 매우 낮기 때문에 데이터를 그대로 사용하기로 한다.
- 상권명:** "두 상권 모두 2024년 4분기까지 과거 명칭을 사용하고 2025년 1분기부터 새 명칭으로 일괄 변경됐다. 이전 명칭은 "혜회동주민센터"에서 "혜화동주민센터"로 KT&G 북부지사에서 KTNG 북부지사로 변경되었으며 오탈자 및 명칭 통합으로 인한 변경으로 추정된다.따라서 명칭은 최신 `trade_area` 명칭을 사용하는 것이 적절하다.